Zápis zo stretnutia

Základné údaje

Projekt	Zber a analýza cien potravín
Dátum a čas stretnutia	8.10 15:00
Miesto / forma	prezenčná
Zúčastnení	Ing. Samuel Gibala, Ing. Matúš Vaňo, Natália Žilová, Nikita Ziborov, Filip Štrba, Martin Ljavo, Nemanja Polić
Zápis vypracoval	Natália Žilová

Zhodnotenie úloh z predchádzajúceho stretnutia

Toto je prvé stretnutie, preto sa zhodnotenie plnenia úloh neuvádza.

Priebeh stretnutia

1. Zber dát (web scraping)

Diskutovalo sa o technickom riešení scrapera, ktoré má byť nezávislé od konkrétnej stránky. Klasický scraper nefunguje na stránkach závislých od JavaScriptu, preto sa zvažujú nástroje Crawl4AI a Scrapy, ktoré dokážu získať obsah aj z takýchto stránok a odovzdať ho jazykovému modelu (LLM). Navrhnutý postup: scraper vytiahne obsah stránky, LLM ho vyparsuje do štruktúry, určí produkt a cenu a následne produkt zaradí do kategórie. Na to sa použije model Qwen, pri ktorom je kľúčové dobre nastaviť prompt a základné kategórie.

2. Kategórie potravín

Kategórie majú byť dostatočne všeobecné na to, aby ich model vedel spoľahlivo priradiť, no zároveň dostatočne konkrétne pre vhodnú granularitu. Zvažuje sa viac kategórií a podkategórií. Z nich sa budú počítať indexy a vývoj cien.

3. Plán zberu a zdroje dát

Dáta sa budú scrapovať vlastnými silami. Plánuje sa nazbierať približne mesiac reálnych dát a zvyšok dopočítať syntetickými dátami. Zber prebehne denne, automaticky napríklad ov2:00 v noci. Primárnym zdrojom sú e-shopy; ďalej Tesco, Košík a Wolt Market,... Možné je aj otestovanie letákov a iných zdrojov. Otvorenou otázkou zostáva riešenie prípadov, keď rovnaký produkt predáva viac obchodov. Dátová analýza následne preskúma rozptyl cien medzi obchodmi a doplnkové informácie.

4. Technické prostredie

Backend v Pythone (FastAPI), frontend Vue, databáza PostgreSQL, nasadenie cez Docker. Webová časť sa vytvorí formou vibecodingu s dôrazom na funkčnosť. Jazykové modely pobežia cez Ollama na CPU. Postup: prvé testy scrapera, potom škálovanie, následne väčší zber a sledovanie napĺňania databázy. Treba ešte rozhodnúť, ktorý zo scrapovacích algoritmov sa nastaví.

5. Webový výstup

Web bude zobrazovať zoznam produktov s filtrom. Po kliknutí na produkt sa zobrazí fotka a graf vývoja ceny spolu s predikciou jej ďalšieho vývoja. Po kliknutí na kategóriu sa zobrazí graf pre celú kategóriu (rast alebo pokles). Používateľ si bude môcť vybrať dva až tri produkty a vytvoriť real-time index. Predikcia ceny a štatistické spracovanie sú ďalšími cieľmi projektu. Najdôležitejšou časťou ostáva zber dát.

6. Organizácia spolupráce

Pre projekt vznikne stránka na webe. Stretnutia sa budú dohadovať na týždennej báze.

Úlohy na ďalšie obdobie

Č.	Úloha	Zodpovedný	Termín
1	Vybrať a otestovať scraper (Crawl4AI / Scrapy) s LLM na JavaScript stránkach		
2	Navrhnúť kategórie a podkategórie potravín a nastaviť prompt pre model Qwen		
3	Pripraviť prostredie: Ollama, Docker, FastAPI, PostgreSQL		
4	Spustiť prvé testy scrapovania na e-shopoch (Tesco, Košík, Wolt Market) a overiť letáky		
5	Nastaviť denný automatický zber o 2:00 a začať zbierať dáta (cieľ ~1 mesiac)		
6	Navrhnúť riešenie pre rovnaké produkty vo viacerých obchodoch		
7	Vytvoriť základ webu (zoznam produktov, filter, detail s grafom)		